

Analiza și înțelegerea setului de date

Descrierea generală a setului de date și a variabilei țintă

În cadrul acestui proiect este utilizat setul de date *Adult* din UCI Machine Learning Repository [1]. Acest set de date este frecvent utilizat în literatura de specialitate pentru evaluarea algoritmilor de clasificare, întrucât conține atât variabile numerice, cât și variabile categoricale, precum și un număr suficient de instanțe pentru antrenarea unor modele fiabile.

Obiectivul principal al setului de date este construirea unui model capabil să prezică dacă venitul anual al unei persoane depășește pragul de 50.000 USD, pe baza unor caracteristici demografice și profesionale extrase din baza de date a recensământului Statelor Unite ale Americii.

Problema formulată este una de învățare supervizată, mai precis de clasificare binară, în care obiectivul este construirea unui model capabil să atribuie fiecărei instanțe una dintre cele două clase posibile pe baza trăsăturilor observate [2].

Setul de date conține un total de **48 842 instanțe** și **14 trăsături**, la care se adaugă o variabilă țintă.

Fie $x = (x_1, x_2, \dots, x_{14})$ vectorul trăsăturilor asociate unei instanțe. Din punct de vedere matematic, obiectivul este estimarea unei funcții:

$$f: \mathbb{R}^{14} \rightarrow \{0,1\}$$

unde rezultatul reprezintă una dintre cele două clase posibile. Modelul de clasificare urmărește, deci, estimarea unei funcții $f(x)$ care asociază vectorului de trăsături una dintre cele două clase.

Fiecare instanță reprezintă o persoană, iar fiecare trăsătură descrie o caracteristică socio-economică relevantă. Trăsăturile pot fi împărțite în două categorii principale: variabile numerice și variabile categoricale.

Setul de date conține următoarele trăsături numerice:

- *age* – vârsta persoanei
- *fnlwgt* – ponderea finală asociată instanței în eșantionul recensământului
- *education-num* – număr de ani de educație formală
- *capital-gain* – câștiguri din capital
- *capital-loss* – pierderi din capital
- *hours-per-week* – număr de ore lucrate pe săptămână

Aceste variabile sunt reprezentate prin valori întregi și pot necesita normalizare sau standardizare în etapele ulterioare de preprocesare.

Trăsăturile categoriale includ:

- *workclass* – tipul angajatorului
- *education* – nivelul de educație
- *marital-status* – statut marital
- *occupation* – ocupația
- *relationship* – relația în cadrul familiei
- *race* – rasă
- *sex* – gen
- *native-country* – țara de origine

Variabila țintă este ***income***. În cadrul analizei preliminare s-a observat existența unor inconsistențe în reprezentarea etichetelor (prezența caracterului "." la finalul unor valori). Acestea au fost corectate prin eliminarea caracterului suplimentar, asigurând astfel existența a două clase distincte:

- $\leq 50K$
- $> 50K$

Pentru a putea lucra cu aceste clase în etapele următoare, ele au fost codificate după cum urmează:

- Clasei „ $\leq 50K$ ” i se atribuie valoarea **0**
- Clasei „ $> 50K$ ” i se atribuie valoarea **1**

Pentru a asigura consistența variabilelor categoriale, au fost eliminate spațiile suplimentare din începutul și sfârșitul valorilor textuale. Operația a fost aplicată exclusiv coloanelor de tip string pentru a evita modificarea variabilelor numerice.

În continuare, raportul este structurat după cum urmează: se analizează distribuția claselor și eventualele probleme de calitate ale datelor, urmate de analiza trăsăturilor numerice și categoriale. În final, se investighează relația dintre trăsături și variabila țintă, cu scopul identificării caracteristicilor informative pentru procesul de clasificare.

Distribuția claselor

În vederea evaluării structurii setului de date și identificării unui posibil dezechilibru între clase, s-a analizat distribuția variabilei țintă *income*.

În prealabil, etichetele au fost armonizate prin eliminarea caracterului „.” și a eventualelor spații suplimentare. Deși acestea au fost codificate pentru prelucrarea numerică, în raport acestea vor fi identificate ca în setul de date:


- ≤50K USD
- >50K USD

Distribuția claselor a fost determinată atât sub formă de număr absolut de instanțe, cât și procentual, raportat la numărul total de observații. Rezultatele analizei sunt prezentate în Tabelul 1.

Income	Număr instanțe	Procent [%]
≤50K	37155	76.07
>50K	11687	23.93

Tabel 1 - Distribuția claselor pentru variabila țintă (income)

Graficul asociat (din Figura 1) evidențiază vizual diferența semnificativă dintre cele două clase, clasa „≤50K” fiind predominantă.



Figură 1 - Distribuția claselor pentru variabila țintă (income)

Analiza distribuției indică faptul că setul de date prezintă un **dezechilibru pronunțat între clase**. Clasa majoritară (≤50K) reprezintă aproximativ 76.07% din totalul observațiilor, în timp ce clasa minoritară (>50K) reprezintă doar 23.93%. Raportul aproximativ dintre clase este:

$$\frac{76.07}{23.93} \approx 3.18$$

Aceasta înseamnă că există de peste trei ori mai multe instanțe în clasa majoritară decât în clasa minoritară.

Dezechilibrul claselor poate avea un impact semnificativ asupra performanței modelelor de clasificare deoarece:

- Modelele pot tinde să favorizeze clasa majoritară.
- Acuratețea (accuracy) poate deveni o metrică înșelătoare.
- Performanța pe clasa minoritară poate fi subestimată.

De exemplu, un model care ar prezice întotdeauna clasa majoritară ar obține o acuratețe de aproximativ 76%, fără a învăța efectiv structura datelor.

În consecință, evaluarea performanței modelelor nu se va baza exclusiv pe acuratețe, ci vor fi utilizate și alte metrici care vor fi descrise ulterior.

Identificarea valorilor lipsă și a problemelor de calitate

Calitatea datelor reprezintă un factor determinant în performanța modelelor de învățare automată. Prezența valorilor lipsă sau a instanțelor duplicate poate să introducă bias, să reducă capacitatea de generalizare a modelelor și să afecteze interpretarea rezultatelor.

În această etapă s-a realizat o analiză sistematică a setului de date *Adult* pentru identificarea valorilor lipsă la nivel de trăsătură și instanțelor duplicate și pentru implementarea unor strategii adecvate de corecție.

În setul de date *Adult*, valorile lipsă nu sunt reprezentate direct prin valori NaN (Not a Number), ci prin simbolul textual „?”, în special în anumite variabile categoriale (de exemplu: *workclass*, *occupation*, *native-country*). Pentru a permite cuantificarea corectă a valorilor lipsă, aceste apariții au fost convertite la reprezentarea standard NaN. Ulterior, pentru fiecare trăsătură s-au calculat numărul absolut de valori lipsă și procentul valorilor lipsă raportat la numărul total de instanțe, după cum reiese din Tabelul 2.

Trăsătură	Număr valori lipsă	Procent valori lipsă [%]
occupation	2809	5.75
workclass	2799	5.73
native-country	857	1.73
education	0	0.00
fnlwgt	0	0.00
age	0	0.00
marital-status	0	0.00
education-num	0	0.00
race	0	0.00
relationship	0	0.00
sex	0	0.00
capital-gain	0	0.00
capital-loss	0	0.00
hours-per-week	0	0.00

Tabel 2 Distribuția valorilor lipsă

Analiza a evidențiat faptul că doar un subset al trăsăturilor este afectat de valori lipsă (respectiv **3** din **14**), iar distribuția acestora este concentrată în variabilele categoriale. Determinarea numărului de trăsături afectate permite evaluarea impactului structural al fenomenului asupra dataset-ului.

Pe lângă valorile lipsă, s-a verificat existența instanțelor duplicate, analizând concatenarea caracteristicilor (X) și a variabilei țintă (y). O instanță a fost considerată duplicat dacă toate valorile trăsăturilor și eticheta asociată erau identice cu cele ale unei observații anterioare. S-au determinat numărul total de instanțe duplicate (**52**) și procentul acestora raportat la dimensiunea totală a setului de date (**0.11%**). Această analiză permite cuantificarea gradului de redundanță în date și evaluarea necesității eliminării observațiilor repetate. După eliminare, indexul setului de date a fost reinițializat pentru a menține coerența structurală.

Pentru valorile lipsă s-a adoptat o strategie de imputare diferită în funcție de tipul variabilei:

a) Variabile numerice

Valorile lipsă au fost înlocuite cu mediana fiecărei coloane. Mediana a fost aleasă în detrimentul mediei aritmetice datorită eficienței sale în cazul valorilor extreme și a distribuțiilor asimetrice (cum este în cazul variabilelor *capital-gain* sau *hours-per-week*), fiind o strategie frecvent utilizată în preprocesarea datelor pentru modele de învățare automată [3].

b) Variabile categoriale

Valorile lipsă au fost înlocuite cu cea mai frecventă categorie a fiecărei trăsături. Această metodă păstrează structura predominantă a distribuției și evită reducerea dimensiunii setului de date prin eliminarea instanțelor incomplete.

Imputarea permite menținerea dimensiunii setului de date, evitând pierderea de informație care ar rezulta din eliminarea instanțelor incomplete.

Analiza trăsăturilor numerice

Pentru fiecare trăsătură numerică au fost calculate statisticile descriptive principale și au fost analizate distribuțiile variabilelor. Această etapă face parte din analiza exploratorie a datelor (Exploratory Data Analysis – EDA), metodă introdusă de Tukey [4], utilizată pentru înțelegerea structurii datelor, identificarea valorilor extreme și evidențierea caracteristicilor principale ale distribuțiilor. Rezultatele se regăsesc în Tabelul 3.

Trăsătură/ Statistică	age	fnlwgt	education- num	capital- gain	capital- loss	hours- per- week
count	48790	48790	48790	48790	48790	48790
mean	38.65	189669	10.08	1080.22	87.6	40.43
std	13.71	105617.2	2.57	7455.91	403.21	12.39
min	17	12285	1	0	0	1
25%	28	117555	9	0	0	40
50%	37	178138.5	10	0	0	40
75%	48	237606.3	12	0	0	45
max	90	1490400	16	99999	4356	99


Tabel 3 - Statistici descriptive pentru trăsăturile numerice

Aceste statistici permit caracterizarea distribuției fiecărei variabile și identificarea unor aspecte relevante precum dispersia datelor, concentrarea valorilor în anumite intervale și


prezența valorilor extreme. În același fel, diferențele dintre medie și mediană (percentila de 50%) indică existența unor distribuții asimetrice.

Analiza deviațiilor standard a evidențiat trăsăturile cu variația cea mai ridicată. În cazul în care numărul total de trăsături este ridicat, se analizează grafic doar primele 15 trăsături cu deviația standard cea mai mare, pentru a evidenția variabilele cu impact mai ridicat asupra modelului. În acest caz setul de date conține doar 6 trăsături numerice, astfel că s-au generat toate histogramele corespunzătoare acestora.

Distribuția trăsăturii **capital-gain** este ilustrată în Figura 2. Variabila prezintă o distribuție extrem de asimetrică, caracterizată printr-o concentrație majoritară a valorilor în 0 și un număr redus de observații cu valori foarte ridicate. Acest lucru este confirmat și de faptul că percentila 25%, mediana (50%) și percentila 75% sunt egale cu 0, în timp ce valorile maxime sunt semnificativ mai mari (ex: **capital-gain** = 99999). Această structură indică o distribuție cu asimetrie pozitivă puternică și justifică aplicarea unei transformări logaritmice sau a unei metode eficiente de scalare. Aceleași concluzii se pot trage și pentru capital-loss (din Figura 3). Această structură sugerează o distribuție puternic concentrată în jurul valorii zero, caracteristică variabilelor economice care apar doar pentru o parte redusă a populației.




Figură 2 - Histogramă capital-gain




Figură 3 - Histogramă capital-loss

Distribuția variabilei hours-per-week (din Figura 4) este discretă și se evidențiază prin o concentrație puternică în jurul valorii 40, corespunzătoare normei standard de muncă.



Figură 4 - Histogramă hours-per-week

Variabila **age** (Figura 5) prezintă o distribuție relativ echilibrată, cu o concentrare a valorilor între 25 și 50 de ani și o ușoară asimetrie pozitivă. Diferența redusă dintre medie și mediană indică absența unor distorsiuni majore.



Figură 5 - Histogramă age

Pentru detectarea valorilor extreme (outliers) s-a utilizat metoda bazată pe intervalul intercuartilic (IQR):

$$Q3 = \text{valoarea de la percentila de } 75\%$$

$$Q1 = \text{valoarea de la percentila de } 25\%$$

$$IQR = Q3 - Q1$$

$$LowerBound = Q1 - 1.5 \cdot IQR$$

$$UpperBound = Q3 + 1.5 \cdot IQR$$

Valorile situate în afara intervalului $[LowerBound, UpperBound]$ au fost considerate posibile outliere. Analiza a evidențiat prezența unor valori extreme în anumite trăsături, în special în variabile cu distribuții puternic asimetrice, aspect reflectat în Tabelul 4.

Trăsătură	Număr outliere	Procent (%)
hours-per-week	13486	27.64
capital-gain	4035	8.27
capital-loss	2282	4.68
education-num	1787	3.66
fnlwgt	1453	2.98
age	215	0.44

Tabel 4 - Distribuție outliere în variabilele numerice

Deși metoda IQR identifică un număr ridicat de outlieri pentru variabila *hours-per-week*, aceste valori reprezintă cazuri reale (de exemplu, program de lucru redus sau program prelungit) și nu indică neapărat erori în date. Prin urmare, aceste valori nu sunt tratate ca erori de măsurare și nu vor fi eliminate din setul de date. În cazul variabilelor *capital-gain* și *capital-loss*, însă, aceste valori necesită o analiză suplimentară deoarece distribuția trăsăturilor este

puternic asimetrică. În contrast, variabilele *age* și *education-num* prezintă distribuții mai echilibrate.

Analiza evidențiază diferențe considerabile între magnitudinile variabilelor:

- *age*: valori între 17 și 90
- *hours-per-week*: între 1 și 99
- *capital-loss*: până la 4356
- *fnlwgt*: până la peste 1.400.000

Rezultatele obținute indică necesitatea aplicării unei etape de standardizare sau normalizare a variabilelor numerice înainte de antrenarea modelelor, în special pentru algoritmi sensibili la scară.

Analiza trăsăturilor categoriale

În această etapă s-au analizat trăsăturile categoriale din setul de date pentru a determina numărul de categorii distincte aferente fiecărei trăsături și proporția fiecărei categorii în raport cu numărul total de instanțe. Scopul analizei este identificarea variabilelor cu cardinalitate ridicată și a categoriilor foarte rare, care pot influența negativ procesul de preprocesare și pot crește dimensionalitatea în cazul codificării One-Hot.

Au fost identificate următoarele trăsături categoriale: *workclass*, *education*, *marital-status*, *occupation*, *relationship*, *race*, *sex*, *native-country*, care se găsesc în Tabelul 5. Cardinalitatea acestora variază semnificativ: de exemplu, *sex* are 2 categorii, în timp ce *native-country* are 41 de categorii distincte. Variabilele cu cardinalitate ridicată (*native-country*, *education*, *occupation*) sunt susceptibile la generarea unui număr mare de variabile în cazul codificării One-Hot, ceea ce poate conduce la o reprezentare sub forma unei matrici rare (în care majoritatea valorilor sunt 0) și la creșterea complexității modelului.

Trăsătură	Număr categorii
native-country	41
education	16
occupation	14
workclass	8
marital-status	7
relationship	6
race	5
sex	2

Tabel 5 - Categorii per trăsătură categorială

Pentru fiecare trăsătură categorială s-a determinat distribuția completă pe categorii (număr de instanțe și procent), obținându-se rezultatele din Tabelele 6-13.

workclass	Număr instanțe	Procent (%)
Private	36655	75.13
Self-emp-not-inc	3861	7.91
Local-gov	3136	6.43

State-gov	1981	4.06
Self-emp-inc	1694	3.47
Federal-gov	1432	2.94
Without-pay	21	0.04
Never-worked	10	0.02

Tabel 6 - Distribuția categoriilor pentru workclass

education	Număr instanțe	Procent (%)
HS-grad	15770	32.32
Some-college	10863	22.26
Bachelors	8013	16.42
Masters	2656	5.44
Assoc-voc	2060	4.22
11th	1812	3.71
Assoc-acdm	1601	3.28
10th	1389	2.85
7th-8th	954	1.96
Prof-school	834	1.71
9th	756	1.55
12th	655	1.34
Doctorate	594	1.22
5th-6th	507	1.04
1st-4th	245	0.50
Preschool	81	0.17

Tabel 7 - Distribuția categoriilor pentru education

marital-status	Număr instanțe	Procent (%)
Married-civ-spouse	22366	45.84
Never-married	16082	32.96
Divorced	6630	13.59
Separated	1530	3.14
Widowed	1518	3.11
Married-spouse-absent	627	1.29
Married-AF-spouse	37	0.08

Tabel 8 - Distribuția categoriilor pentru marital-status

occupation	Număr instanțe	Procent (%)
Prof-specialty	8970	18.38
Craft-repair	6102	12.51
Exec-managerial	6082	12.47
Adm-clerical	5606	11.49
Sales	5501	11.27
Other-service	4919	10.08
Machine-op-inspct	3017	6.18
Transport-moving	2355	4.83
Handlers-cleaners	2071	4.24
Farming-fishing	1485	3.04
Tech-support	1445	2.96
Protective-serv	982	2.01
Priv-house-serv	240	0.49
Armed-Forces	15	0.03

Tabel 9 - Distribuția categoriilor pentru occupation

relationship	Număr instanțe	Procent (%)
Husband	19703	40.38
Not-in-family	12557	25.74
Own-child	7569	15.51
Unmarried	5124	10.50
Wife	2331	4.78
Other-relative	1506	3.09

Tabel 10 - Distribuția categoriilor pentru relationship

race	Număr instanțe	Procent (%)
White	41714	85.50
Black	4683	9.60
Asian-Pac-Islander	1517	3.11
Amer-Indian-Eskimo	470	0.96
Other	406	0.83

Tabel 11 - Distribuția categoriilor pentru race

sex	Număr instanțe	Procent (%)
Male	32614	66.85
Female	16176	33.15

Tabel 12 - Distribuția categoriilor pentru sex

native-country	Număr instanțe	Procent (%)
United-States	44648	91.51
Mexico	943	1.93
Philippines	294	0.6
Germany	206	0.42
Puerto-Rico	184	0.38
Canada	182	0.37
El-Salvador	155	0.32
India	151	0.31
Cuba	138	0.28
England	127	0.26
China	122	0.25
South	115	0.24
Jamaica	106	0.22
Italy	105	0.22
Dominican-Republic	103	0.21
Japan	92	0.19
Poland	87	0.18
Guatemala	86	0.18
Vietnam	86	0.18
Columbia	85	0.17
Haiti	75	0.15
Portugal	67	0.14
Taiwan	65	0.13
Iran	59	0.12
Greece	49	0.1
Nicaragua	49	0.1
Peru	46	0.09
Ecuador	45	0.09
France	38	0.08
Ireland	37	0.08
Thailand	30	0.06
Hong	30	0.06
Cambodia	28	0.06
Trinidad&Tobago	27	0.06
Laos	23	0.05
Yugoslavia	23	0.05
Outlying-US(Guam-USVI-etc)	23	0.05
Scotland	21	0.04
Honduras	20	0.04
Hungary	19	0.04
Holand-Netherlands	1	0.002

Tabel 13 - Distribuția categoriilor pentru native-country

Datele arată o concentrare puternică a instanțelor în categoria United-States (peste 90%), ceea ce indică o distribuție extrem de dezechilibrată a acestei variabile (Tabelul 13).

Nu există un prag universal sub care o categorie să fie considerată rară. În acest raport o categorie a fost considerată rară dacă apare în mai puțin de 1% din instanțe. Rezultatele evidențiază existența unor categorii cu pondere extrem de redusă, de exemplu:

- *Holand-Netherlands* în cadrul *native-country* (categoria apare o singură dată în setul de date, corespunzând unei proporții de $\sim 0.002\%$),
- *Never-worked* în cadrul *workclass* ($\sim 0.02\%$),
- *Armed-Forces* în cadrul *occupation* ($\sim 0.03\%$),
- *Married-AF-spouse* în cadrul *marital-status* ($\sim 0.08\%$),
- *Preschool* în cadrul *education* ($\sim 0.17\%$).

Observarea acestor categorii rare este importantă deoarece, în cazul codificării One-Hot, fiecare categorie generează o variabilă binară separată. Categoriile foarte rare conduc astfel la variabile aproape constante (majoritar 0), crescând dimensionalitatea fără a furniza informație predictivă semnificativă și putând favoriza supraînvățarea.

Pe baza cardinalității și a distribuției pe categorii, s-a stabilit următoarea strategie de codificare pentru etapa ulterioară de preprocesare:

- **Codificare binară** pentru variabile dicotomice (ex.: *sex*), deoarece acestea pot fi reprezentate eficient printr-o singură variabilă 0/1, fără creștere dimensională.
- **One-Hot Encoding** este utilizat pentru variabilele cu cardinalitate mică sau moderată (de exemplu *race*, *relationship*, *marital-status* sau *workclass*), deoarece această metodă transformă fiecare categorie într-o variabilă binară distinctă, fără a introduce o relație de ordine artificială între categorii. Astfel, se păstrează natura nominală a variabilelor categoriale, iar reprezentarea rezultată este compatibilă cu majoritatea algoritmilor de clasificare utilizați în învățarea automată.
- Pentru variabile cu cardinalitate ridicată (în special *native-country* și, în anumite configurații, *occupation*), se recomandă **One-Hot Encoding combinat cu tratarea categoriilor rare**, prin gruparea acestora într-o categorie comună (de tip „Other”), cu scopul reducerii dimensionalității.

În această etapă, conform cerinței, codificarea nu este aplicată efectiv, dar analiza și deciziile propuse constituie fundamentul pentru etapa următoare de transformare a variabilelor în format numeric și de antrenare a modelelor.


Analiza exploratorie are rolul de a facilita înțelegerea structurii datelor și de a ghida deciziile de preprocesare și selecție a trăsăturilor înainte de antrenarea modelelor de învățare automată. Acest proces evidențiază câteva aspecte importante pentru etapa de modelare. În primul rând, setul de date prezintă un dezechilibru semnificativ între clase, ceea ce impune utilizarea unor metrice de evaluare potrivite. În al doilea rând, diferențele de scară între variabilele numerice justifică aplicarea unei metode de standardizare. În plus, existența categoriilor rare în variabilele categoriale sugerează necesitatea unui tratament adecvat înaintea codificării One-Hot.

Relația dintre trăsături și target

În această etapă a fost analizată relația dintre trăsăturile numerice și variabila țintă *income*, cu scopul identificării variabilelor care pot avea un impact semnificativ asupra procesului de clasificare. Pentru această analiză a fost utilizat coeficientul de corelație Pearson, care măsoară intensitatea și direcția relației liniare dintre două variabile numerice.

Deoarece variabila țintă este binară (0 – venit $\leq 50K$, 1 – venit $> 50K$), corelația Pearson calculată între aceasta și variabilele numerice este echivalentă cu coeficientul de corelație Point-biserial, utilizat pentru a evalua relația dintre o variabilă numerică și una dicotomică.

Pentru analiza relațiilor dintre variabile s-a calculat matricea de corelație între toate trăsăturile numerice și variabila țintă. Rezultatele sunt prezentate în Figura 6 sub forma unui heatmap.



Figură 6 - Matricea de corelație între trăsăturile numerice și income

Analiza coeficienților de corelație evidențiază faptul că variabila *education-num* prezintă cea mai ridicată corelație cu variabila țintă ($r = 0.33$). Acest rezultat sugerează o asociere pozitivă între nivelul educațional și probabilitatea ca o persoană să aparțină clasei de venituri ridicate ($> 50K$). Din punct de vedere socio-economic, această relație este de așteptat, deoarece un nivel educațional mai ridicat este frecvent asociat cu oportunități profesionale mai bune și, implicit, cu venituri mai mari.


De asemenea, variabilele *age* și *hours-per-week* prezintă valori moderate ale coeficientului de corelație cu variabila țintă (aproximativ $r = 0.23$). Aceste rezultate indică faptul că persoanele mai în vârstă sau cele care lucrează un număr mai mare de ore pe săptămână tind să aibă o probabilitate mai mare de a aparține clasei de venituri ridicate.

Variabila *capital-gain* prezintă de asemenea o corelație pozitivă cu variabila țintă ($r = 0.22$). Totuși, distribuția acestei variabile este puternic asimetrică, majoritatea valorilor fiind egale cu zero, iar valorile pozitive aparând relativ rar. Prin urmare, corelația observată este influențată în mare parte de un număr redus de observații cu valori ridicate.


În schimb, variabila *fnlwgt* prezintă o corelație aproape nulă cu variabila țintă ($r \approx -0.01$), sugerând o relevanță foarte redusă pentru sarcina de clasificare. Acest rezultat este de așteptat, deoarece această variabilă reprezintă o greutate statistică utilizată în procesul de eșantionare al recensământului și nu o caracteristică socio-economică directă a individului.

Valorile coeficienților de corelație sunt relativ reduse, ceea ce este frecvent în cazul datelor socio-economice, unde venitul este influențat de un număr mare de factori interdependenți.


Pe baza valorilor coeficientului de corelație, variabilele *education-num*, *age* și *hours-per-week* pot fi considerate trăsături informative pentru predicția variabilei țintă. În schimb, variabila *fnlwgt* poate fi considerată puțin relevantă pentru această sarcină de clasificare. Pentru o analiză vizuală suplimentară, au fost reprezentate grafic distribuțiile acestor trei trăsături în raport cu variabila țintă, evidențiind diferențele dintre cele două clase de venit.



Figură 7 - Distribuția variabilei *education-num* în funcție de *income*



Figură 8 - Distribuția variabilei age în funcție de income



Figură 9 - Distribuția variabilei hours-per-week în funcție de income

Analiza relațiilor dintre trăsături și variabila țintă indică faptul că anumite caracteristici socio-economice, precum nivelul educațional, vârsta și numărul de ore lucrate, sunt strâns legate, așa cum se intuia, de nivelul veniturilor. Aceste observații vor ghida selecția trăsăturilor și etapa de modelare din fazele următoare ale proiectului.

O precizare importantă: coeficientul de corelație Pearson măsoară doar relații liniare între variabile. Prin urmare, existența unei corelații reduse nu implică neapărat lipsa utilității unei trăsături, deoarece relațiile dintre variabile și variabila țintă pot fi neliniare sau pot apărea în combinație cu alte trăsături.

Bibliografie

- [1] Becker, B., & Kohavi, R. (1996). Adult. UCI Machine Learning Repository.
<https://doi.org/10.24432/C5XW20>
- [2] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- [3] Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly Media.
- [4] Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.